ANALÍTICA DE DATOS
SEGUIMIENTO 2

200 REGISTROS

CINE



ANÁLISIS EXPLORATORIO

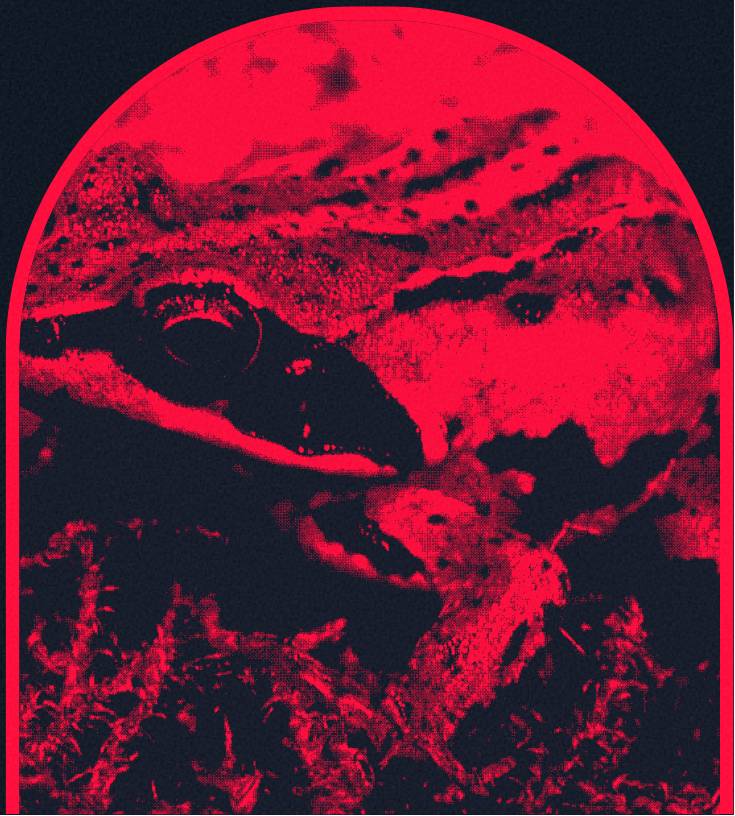
Distribución, valores atípicos y correlación de las calificaciones de películas con Python y pandas.

OCTUBRE 2026

01

DATOS

Actividad 1. Tamaño, tipos, nulos, duplicados y ajuste de memoria del archivo.



INSPECCIÓN Y CALIDAD DE LOS DATOS

DATOS DEL ESTUDIANTE	
Nombre completo	
Ficha / grupo	
Fecha de entrega	

REVISIÓN	RESULTADO
Registros y variables	200 filas y 13 columnas. Cada fila es una calificación de una persona a una película.
Variables numéricas	7: `anio_lanzamiento`, `duracion_minutos`, `presupuesto_produccion_usd_aprox`, `rating_publico_referencia_aprox`, `edad_persona`, `calificacion_personal_1_a_10`, `probabilidad_recomendar_0_a_100`.
Variables categóricas	5 de texto con pocos valores repetidos. `id_calificacion` es solo un identificador: no se promedia ni entra en correlaciones.
Faltantes y duplicados	0 valores faltantes en las 13 columnas y 0 filas duplicadas.
Decisiones	No hay nada que imputar ni eliminar. Los tipos son correctos; solo se reducen en memoria. La nota queda como decimal porque hay medios puntos (5,5; 6,5; 9,5).

TIPOS DE DATOS Y MEMORIA

pandas asigna **int64** a todo entero, aunque la edad nunca pasa de 51. En un archivo de 200 filas no importa; si la base crece, cada columna ocupa ocho veces más de lo necesario. La función *optimizar_tipos* elige el tipo más pequeño que contiene el rango real.

VARIABLE	RANGO REAL	TIPO ORIGINAL	TIPO NUEVO	LÍMITE DEL TIPO
`edad_persona`	16 a 51	int64	**int8**	127
`probabilidad_recomendar`	0 a 100	int64	**int8**	127
`anio_lanzamiento`	1972 a 2024	int64	**int16**	32.767
`duracion_minutos`	81 a 195	int64	**int16**	32.767
`presupuesto_produccion`	3,3 M a 356 M	int64	**int32**	2.147 M
`rating_publico`, `nota`	7,2 a 9,3 · 1 a 10	float64	float64	sin cambio

RIESGO DE DESBORDAMIENTO

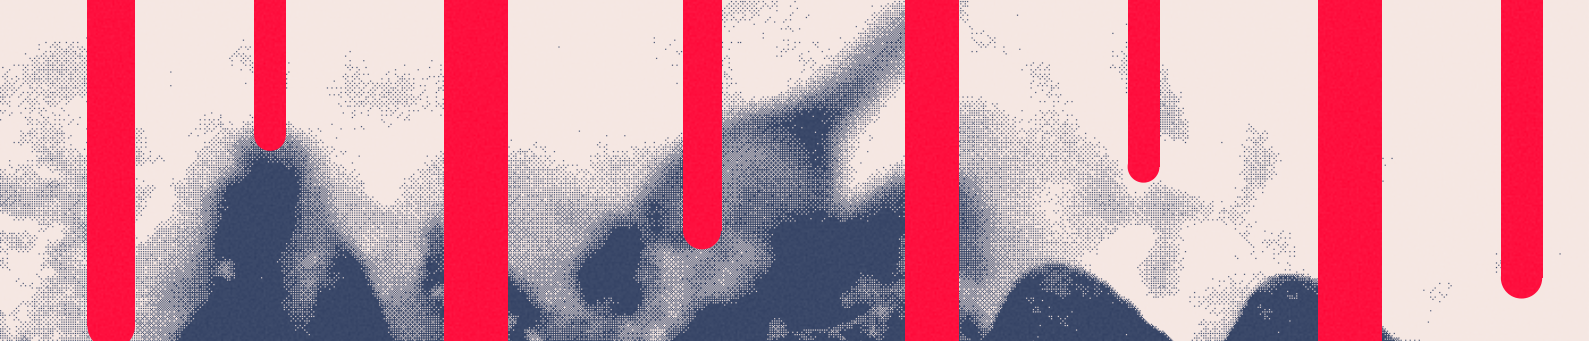
Un int8 llega a 127. Edad (máx. 51) y probabilidad (máx. 100) caben, pero si el rango pudiera crecer se usa int16 o uint8 (0 a 255). La duración sí exige int16: 195 no cabe en int8. El presupuesto necesita int32 porque supera 32.767.

MEMORIA EN ESTE EQUIPO	ANTES	DESPUÉS	AHORRO
Las 13 columnas	30,8 KB	10,9 KB	65 %

02

DISTRIBUCIÓN

Actividades 2 y 3. Histograma, diagramas de caja y valores atípicos.



HISTOGRAMA DE LAS CALIFICACIONES

DISTRIBUCIÓN DE LA CALIFICACIÓN PERSONAL

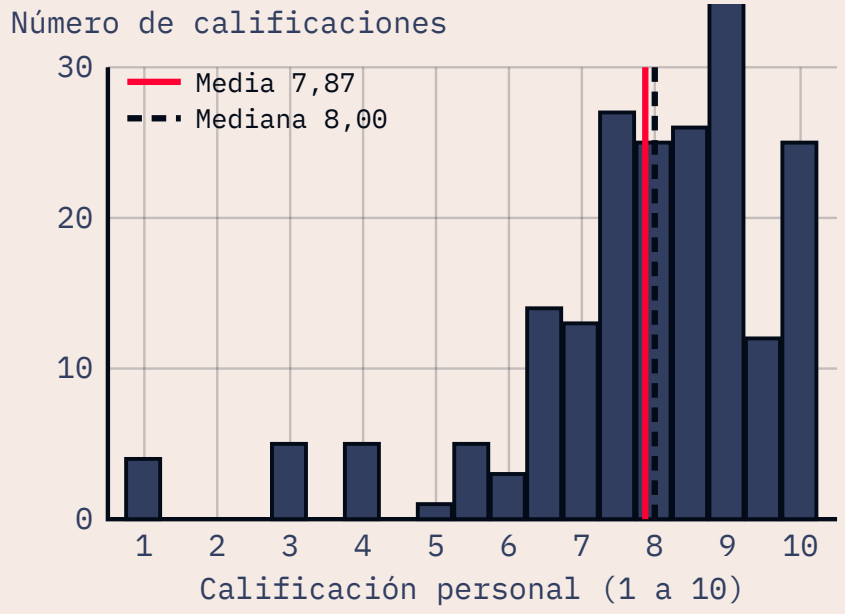


Figura 1. Histograma de calificacion_personal_1_a_10, barras de medio punto.

9,0
moda, 35 registros

8,0
mediana

7,87
media

1,83
desviación estándar

-1,62
asimetría

INTERPRETACIÓN

Concentración. Las notas se juntan arriba: 123 de 200 (61,5 %) son 8 o más y 163 (81,5 %) son 7 o más. El pico está en 9, seguido de un bloque de 25 dieces. La media queda bajo la mediana y esta bajo la moda.

Cuidado. Son 200 respuestas simuladas de perfiles distintos, no los gustos de una sola persona, y las películas del archivo son muy reconocidas. Ambas cosas empujan las notas hacia arriba.

DIAGRAMAS DE CAJA

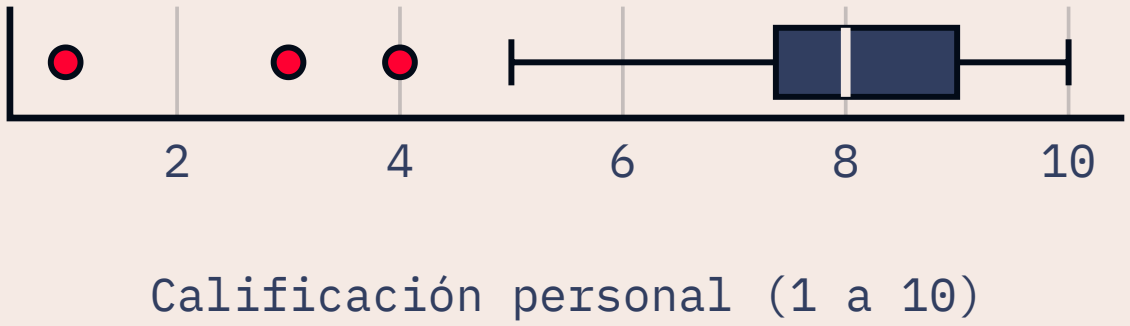


Figura 2. Diagrama de caja de la calificación personal.

MEDIDAS GENERALES	Q1	MEDIANA	Q3	IQR	BIGOTES	PUNTOS ATÍPICOS
Calificación personal	7,375	8,0	9,0	1,625	5,0 a 10,0	1 (×4), 3 (×5), 4 (×5): 14 puntos

CALIFICACIÓN PERSONAL POR MEDIO DE VISUALIZACIÓN

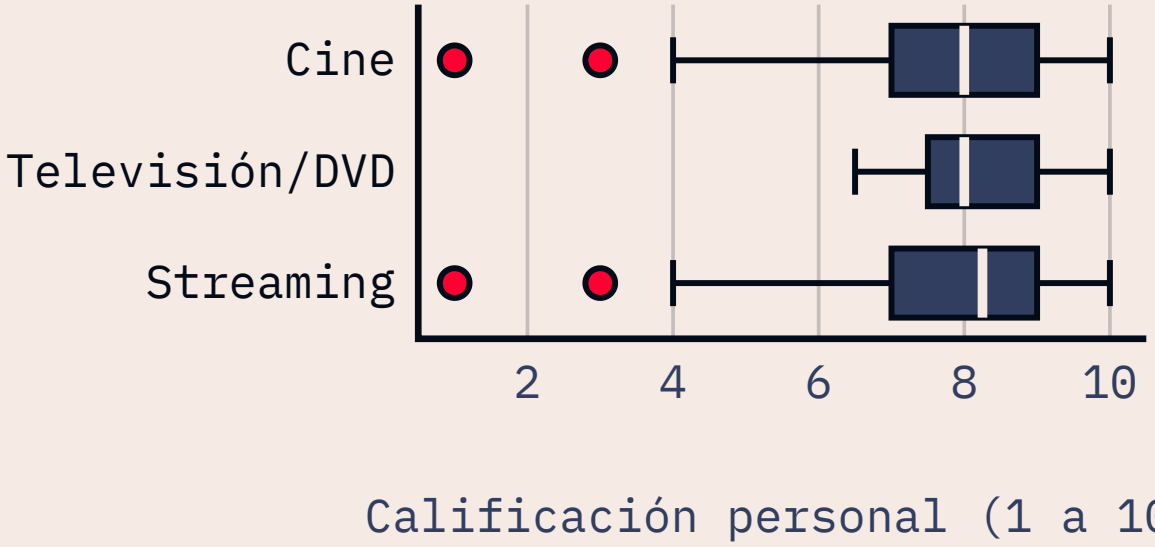


Figura 3. Calificación personal según el medio de visualización.

MEDIO	N	MEDIANA	Q1 A Q3	IQR	BIGOTE INF.	DESV.	ATÍPICOS
Cine	52	8,0	7,0 a 9,0	2,0	4,0	2,04	1, 1, 3
Streaming	128	8,25	7,0 a 9,0	2,0	4,0	1,85	1, 1, 3, 3, 3, 3
Televisión/DVD	20	8,0	7,5 a 9,0	1,5	6,5	0,97	ninguno

DISPERSIÓN Y VALORES ATÍPICOS

¿QUÉ POSIBLES VALORES ATÍPICOS SE OBSERVAN?

Generales: 1, 3 y 4. **Por medio:** Cine 1, 1, 3; Streaming 1, 1, 3, 3, 3, 3; Televisión/DVD ninguno.

¿POR QUÉ UN VALOR ATÍPICO NO ES NECESARIAMENTE UN ERROR?

Un atípico solo está lejos de su grupo; no dice que esté mal. Aquí todos caben en la escala de 1 a 10, no hay valores imposibles ni mal digitados, y un 1 es una opinión real de alguien a quien no le gustó la película.

Decisión: no se eliminó ninguno. Son el 7 % de los datos y muestran desacuerdo. Quitarlos subiría la media de 7,87 a 8,25 y haría ver un consenso que no existe.

03

RELACIONES

Actividades 4 y 5. Dispersión, tendencia y matriz de Pearson.



NOTA VS. VALORACIÓN PÚBLICA

CALIFICACIÓN PERSONAL VS. VALORACIÓN PÚBLICA

SIMULACIÓN · PUNTOS DE MUESTRA; LA TENDENCIA Y R SON LOS DEL PDF DE REFERENCIA

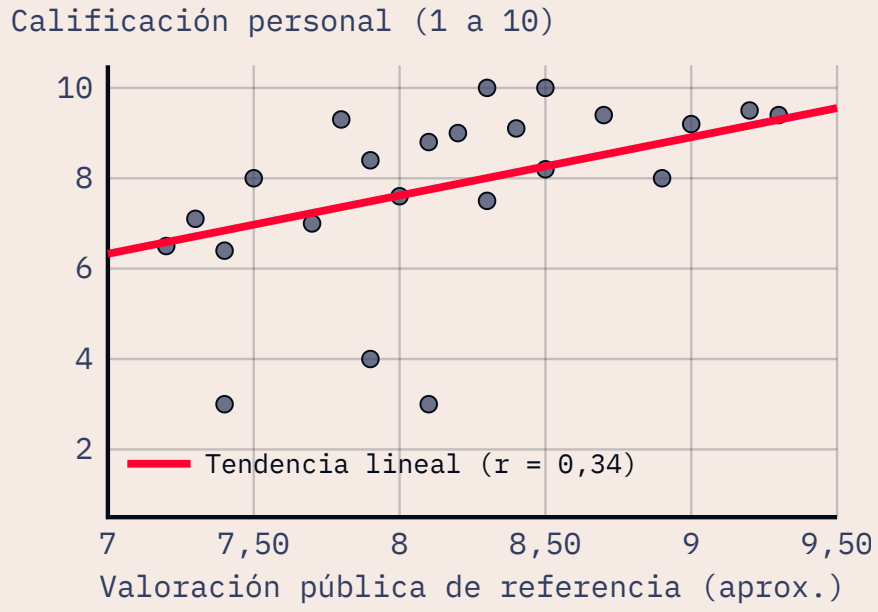


Diagrama 1. Calificación personal vs. valoración pública de referencia.

0,34
r de Pearson

0,38
rho de Spearman

Pendiente: 1,29 puntos de nota por cada punto de valoración pública.

INTERPRETACIÓN

La tendencia sube: las películas mejor valoradas por el público reciben, en promedio, notas más altas. La relación es débil a moderada: la nube es ancha y r^2 es 0,11. **Cuidado.** La correlación no prueba que el público influya en la persona.

MATRIZ DE CORRELACIÓN

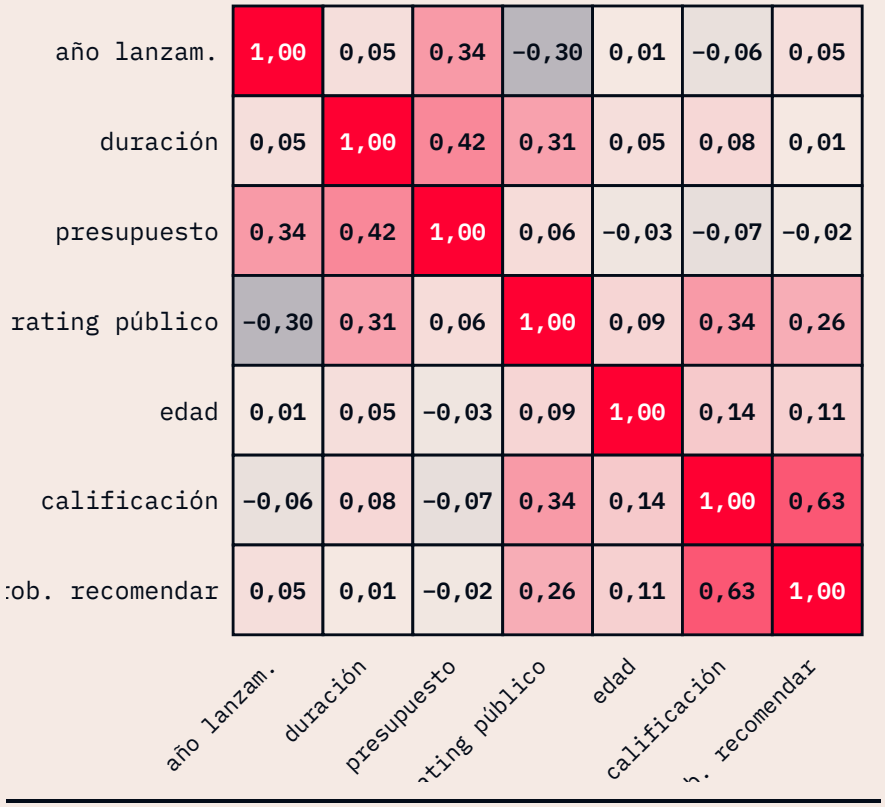


Figura 5. Mapa de calor de la correlación de Pearson entre las 7 variables numéricas.

0,63

nota personal y probabilidad de recomendar: la más alta

−0,30

año de lanzamiento y rating público: la más negativa

0,01

año de lanzamiento y edad: casi cero

PREGUNTA	RESPUESTA
Mayor positiva	`calificacion_personal` y `probabilidad_recomendar`, r = 0,63: moderada a alta.
Mayor negativa	`anio_lanzamiento` y `rating_publico`, r = −0,30: débil a moderada.
Cerca de cero	`anio_lanzamiento` y `edad_persona`, r = 0,01.

04

SÍNTESIS

Actividad 6. Conclusiones y revisión de las respuestas.

SÍNTESIS DE RESULTADOS

HALLAZGO PRINCIPAL SOBRE LAS CALIFICACIONES

Las calificaciones son altas y asimétricas: mediana 8, moda 9, media 7,87 y asimetría −1,62. El 81,5 % es 7 o más. El problema no está en el centro sino en la cola: 14 notas bajas (1, 3 y 4) que no son errores sino desacuerdos reales.

¿QUÉ VARIABLES SE RELACIONAN CON LA CALIFICACIÓN Y CON QUÉ INTENSIDAD?

VARIABLE	PEARSON	SPEARMAN	LECTURA
Probabilidad de recomendar	0,63	0,67	Moderada a alta; es casi la misma opinión dicha de otra forma.
Rating público	0,34	0,38	Débil a moderada; explica cerca del 11 % de la variación.
Edad	0,14	0,10	Muy débil.
Duración	0,08	0,09	Prácticamente nula.
Año de lanzamiento	−0,06	−0,04	Prácticamente nula.
Presupuesto	−0,07	−0,06	Prácticamente nula.

LO QUE SÍ Y LO QUE NO SE PUEDE DECIR

Esto describe asociación, no causa: ninguna de estas variables demuestra por sí sola que provoque la nota. Los datos son simulados y hay 50 películas con 4 calificaciones cada una, así que las filas no son totalmente independientes.